

Block B — indel 구조 인코더 설명

DeepRAD51C / 조원 공유용 / 구조 정보를 벡터로 바꾸는 원리

1. 먼저 — indel은 왜 특별한가

단백질은 아미노산 사슬이 접혀 3D 구조를 이루고, 그 구조가 기능을 한다. 변이가 이 구조를 얼마나 망가뜨리는지가 곧 기능 손상 정도다. 그런데 indel(삽입/결실)은 SAV(한 아미노산 치환)와 구조적으로 완전히 다른 사건이다.

① SAV
치환



길이/위치 그대로 → 점 하나

② 결실
잘라내고 봉합



토막 제거 → 남은 양끝 다시 이음

③ 삽입
끼워넣어 길어짐



잔기 삽입 → 길이 증가

그림 A. SAV는 길이가 그대로지만, 결실은 토막을 잘라 양끝을 다시 잇고, 삽입은 사슬을 늘린다.

핵심 차이 4가지

① 소수성 코어: 묻힌 잔기는 구조의 기둥, 표면 잔기는 여유가 있다. ② 백본 연결성: 결실은 사슬을 자르고 다시 이어야 하며, 연속된 Cα 간격은 ~3.8Å로 고정돼 있다. ③ 2차 구조 주기성: helix/sheet 중간을 건드리면 규칙적 수소결합이 어긋나지만 loop는 유연해 잘 버틴다. ④ 삽입 비대칭: 삽입 잔기는 들어갈 공간이 필요하다.

2. 재봉합 사건 — Block B의 핵심 아이디어

결실에서 가장 중요한 건 '무엇을 뺐나'보다 '자른 두 끝을 다시 이을 수 있나'이다. 남은 두 잔기(p-1, q+1)가 3D에서 가까우면 쉽게 봉합되고, 멀면 억지로 이어야 해 구조가 깨진다.




그림 B. 같은 3-residue 결실이라도 표면 loop는 양끝이 가까워 관대, core는 멀어 치명적. 시작점 하나만 보면 이 차이가 구분되지 않는다.

그래서 Block B는 residue를 나열하는 대신 이 재봉합 사건의 구조적 결과를 인코딩한다.

3. pLDDT를 왜 쓰나 (자주 받는 질문)

pLDDT는 원래 AlphaFold의 예측 신뢰도(0~100)다. 그런데 핵심 반전: AF가 확신 못 하는 곳은 대개 구조가 원래 흐물거리는 곳이다. 결정구조로 학습한 AF는 구조가 명확한 곳에서만 확신하고, 무질서/유연 영역에선 확신하지 못한다. 그래서 pLDDT를 사실상 '단단한가 / 흐물거리는가' (강성) 프록시로 쓴다.




그림 C. RAD51C는 양 말단이 흐물거리고(pLDDT ~30) ATPase core가 단단하다(~95). 단단한 곳(높은 pLDDT) 결실이 훨씬 치명적이다.

rSASA와는 다른 축이다

	측정하는 것	축
rSASA	묻혔나 / 노출됐나	공간 (core vs 표면)
pLDDT	단단한가 / 흐물거리나	동역학 (rigid vs flexible)

둘은 관련 있지만(RAD51C에서 상관 -0.66) 동일하진 않다. 표면 loop와 무질서한 꼬리를 rSASA만으론 구분 못 하는데, pLDDT가 그 유연성 차이를 잡아준다.

4. Block B 전체 구성

최종 벡터 = Block A(11, 앵커 한 점 구조) + Block B(11, indel 재통합) + 타입 one-hot(3) = 25-dim. Block B는 indel에서만 채워지고 SAV는 전부 0이다.

그룹	feature	무엇을 / 왜 (생물학)
재통합 기하	junction_strain	양끝 Cα 거리 / 3.8Å — 직접 통합 가능성
	junction_orient_cos	양끝 사슬 방향 정렬 — 매끄럽게 이어지나
	seam_both_loop	양끝 둘 다 loop인가 (깔끔한 절제)
영향 구간	span_min2_rsasa	가장 묻힌 2잔기 — 코어를 지우나
	span_max2_plddt	가장 단단한 2잔기 — 단단한 곳을 지우나
	span_frac_ss	helix+sheet 비율 — 2차구조 파괴
	span_min_site_dist	기능 자리(ATP/interface)를 건드리나
흉터 자리	seam_mean_rsasa	통합 지점이 묻혔나 / 표면인가
연결성	span_external_contacts	제거 조각이 나머지와 얼마나 얹혔나
크기	del_len_norm / ins_len_norm	결실 / 삽입 길이

변이 종류는 마지막 one-hot [sav, del, ins]가 지정한다.

5. 계산 디테일 두 가지

junction_orient_cos: 왼쪽 끝으로 들어오는 사슬 방향 $a = C\alpha(p-1) - C\alpha(p-2)$, 오른쪽에서 나가는 방향 $b = C\alpha(q+2) - C\alpha(q+1)$ 의 코사인. 같은 방향이면 매끄럽게 이어지고 반대면 통합 시 꺾인다.




그림 D. orient_cos = 두 사슬 끝 방향벡터의 코사인.

min2 (min 대신 최소 2개의 평균): 구간에서 '가장 묻힌/단단한' 잔기를 볼 때 하나(min)만 보면 극단치 하나에 흔들린다. 2개 평균으로 robust하게 만들었다. multi-residue indel이 많은 다른 유전자로 확장할 때 특히 유리하다.

6. 실제 데이터로 검증

RAD51C SGE 실험값(z_score ; 낮을수록 기능 손상)과 각 구조 feature의 상관을 봤다. '구조가 파괴적이면 z 가 낮아진다'는 예측 방향이 맞으면 성공이다. (결실 357개 기준)




그림 E. 구조 feature $\leftrightarrow$ z_score 상관. 방향이 모두 예측대로다. junction_strain만 무신호(아래 한계 참고).

종합하면 구조 정보만으로 z_score 를 예측하는 간단한 회귀가 한 번도 안 본 test에서 Pearson $r = +0.49$, depleted 분류 AUC = 0.797를 낸다. 구조 인코딩이 실제 기능 신호를 담고 있다는 뜻이다.

7. 정직한 한계

- ① junction_strain / orient_cos 무신호: 이 데이터의 결실이 거의 다 1-residue라 재봉합 gap이 변이마다 거의 안 변해 변별력이 없다. multi-residue 결실이 많은 유전자에서 살아남 feature라 확장성 위해 유지.
- ② span pooling ~ 앵커: 마찬가지로 1-residue 결실에선 구간이 시작점 하나라 span feature가 Block A 앵커와 같아진다. 이 역시 multi-residue에서만 값을 한다.
- ③ pLDDT는 직접 측정이 아니라 모델 프록시다. 더 엄밀히는 결정구조 B-factor나 MD 요동을 쓰지만 RAD51C엔 없어 실무적 최선으로 AF pLDDT를 쓴다 (실제로 잘 작동).