

# DeepRAD51C — 구조 정보 Encoding 진행상황

RAD51C 변이 효과 예측 모델의 구조 feature 파트 / 작성일 2026-07-12

## 1. 프로젝트 한눈에

RAD51C(376 aa) 단백질의 변이가 기능에 미치는 영향을 예측하는 모델을 만드는 중이며, 그중 구조 정보를 벡터로 인코딩하는 부분을 이번에 구현했다. 다루는 변이는 SAV(단일 아미노산 치환, missense)와 in-frame indel(결실/삽입) 두 종류다. nonsense / frameshift / splice / intron / synonymous는 범위에서 제외했고, 이번 인코딩은 구조 feature만 사용한다(ESM 임베딩 / LLR/PLLR은 넣지 않음).

각 변이는 최종적으로 25차원 구조 feature 벡터로 표현된다:

| 블록      | 차원 | 내용                                                       | 언제 채워지나                      |
|---------|----|----------------------------------------------------------|------------------------------|
| Block A | 11 | 앵커 residue 한 점의 구조 (pLDDT, 2차구조, 표면노출, 기능자리 6곳까지 거리)     | 모든 변이 (indel=시작위치, SAV=치환위치) |
| Block B | 11 | indel '자르고 다시 잇는 사건'의 구조적 결과 (재봉합 기하 + 영향 구간 + 흉터 + 연결성) | indel만 (SAV는 전부 0)           |
| one-hot | 3  | [sav, del, ins] 3-way 구분                                 | 모든 변이                        |

Block B(11-dim) 세부 구성

| 그룹                     | dim | 주요 feature                                                         |
|------------------------|-----|--------------------------------------------------------------------|
| ① 재봉합 기하               | 3   | junction_strain, junction_orient_cos, seam_both_loop               |
| ② 영향 구간 (span pooling) | 4   | span_min2_rsasa, span_max2_plddt, span_frac_ss, span_min_site_dist |
| ③ 흉터 자리                | 1   | seam_mean_rsasa                                                    |
| ④ 연결성                  | 1   | span_external_contacts                                             |
| ⑤ 크기                   | 2   | del_len_norm, ins_len_norm                                         |

## 2. 핵심 결과

### 2.1 데이터

scope 적용 후 총 4914개 변이: SAV 4555 / 결실 357 / 삽입 2. (split: train 3449 / val 723 / test 742, position 기반 분할 유지)

### 2.2 검증 — 결실에서 구조 feature가 실제 z\_score와 상관있나

z\_score가 낮을수록 기능 손상(depleted). '구조가 더 파괴적이면 z가 낮아진다'는 예측이 맞는지 확인.

| feature                  | $\rho$ (결실) | 해석                             |
|--------------------------|-------------|--------------------------------|
| A_plddt                  | -0.599      | 잘 접힌 core 결실 → 손상              |
| B_seam_mean_rsasa        | +0.501      | 표면 흉터 → 관대                     |
| B_span_external_contacts | -0.443      | 촘촘히 박힌 조각 결실 → 손상 (Block B 핵심) |
| B_span_min2_rsasa        | +0.442      | 문힌 residue 결실 → 손상             |
| B_junction_strain        | +0.002      | 무신호 — 결실이 대부분 1-residue        |

### 2.3 구조-only 예측 baseline (Ridge 회귀, torch 없이)

구조 25-dim만으로 z\_score를 예측. train으로 학습, 한 번도 안 본 test로 평가.

| 구분    | n    | Pearson r | Spearman $\rho$ |
|-------|------|-----------|-----------------|
| train | 3449 | +0.480    | +0.430          |
| val   | 723  | +0.502    | +0.500          |

| 구분         | n   | Pearson r | Spearman $\rho$ |
|------------|-----|-----------|-----------------|
| test       | 742 | +0.495    | +0.431          |
| test / SAV | 689 | +0.389    | +0.351          |
| test / 결실  | 52  | +0.493    | +0.430          |

분류(depleted vs unchanged): 같은 구조 예측 점수로 test AUC = 0.797 (n=740). → 구조 정보만으로도 기능 손상 변이를 꽤 잘 가려낸다.

### 3. 파일 안내 — 각 파일이 무엇인가

#### 코드 파일 (code/)

| 파일                 | 역할                                                                                                |
|--------------------|---------------------------------------------------------------------------------------------------|
| block_b.py         | 핵심. build_block_a()로 구조 11-dim 테이블 계산, BlockBEncoder로 indel 11-dim 인코딩, encode_full()로 25-dim 조립. |
| assemble.py        | 조립기 데모. sav/del/ins 예시가 올바른 25-dim이 되는지 확인.                                                       |
| build_dataset.py   | split_manifest.csv를 파싱해 전체 [4914,25] feature 표 생성.                                                |
| analysis.py        | 구조 feature 진단 + Ridge 예측 baseline (분석 결과 JSON 저장).                                                |
| generate_report.py | 이 PDF 리포트 생성.                                                                                     |
| explain_blockb.py  | 조원 설명용 그림 PDF(Block_B_설명.pdf) 생성.                                                                 |

#### 결과 파일 (results/)

| 파일                         | 내용                                         |
|----------------------------|--------------------------------------------|
| rad51c_X.npy               | 모델 입력. [4914, 25] float 구조 feature 행렬.     |
| rad51c_y.npy               | 라벨. [4914] z_score_D4_D14 (회귀 타깃).         |
| rad51c_struct_features.csv | 사람용 통합표. var_id / split / 라벨 + 25 feature. |
| rad51c_meta.csv            | 변이 메타 (var_id, split, type, 위치, 길이, 라벨).   |
| rad51c_blockA.csv          | residue별 Block A 12-dim 구조 테이블 (376행).     |
| analysis_results.json      | 분석 수치 (상관 / baseline / AUC) 원본.            |

#### 입력 파일 (inputs/)

| 파일                            | 내용                                                           |
|-------------------------------|--------------------------------------------------------------|
| AF-043502-F1.pdb              | RAD51C AlphaFold WT 구조 (모든 구조 feature의 원천).                  |
| rad51c_residue_annotation.csv | 기능 자리(Walker A/B, ATP, ssDNA, BCDX2/CX3) 정의 — 거리 계산용.        |
| split_manifest.csv            | SGE 실험 데이터: 변이 위치 / 타입 / 변이서열 / z_score / train/val/test 분할. |
| wt_sequence.txt               | RAD51C WT 아미노산 서열 (376 aa, 검증용).                             |

### 4. 설계 결정과 근거

- 구조만 사용 — 이 파트는 ESM 임베딩 / LLR과 독립적으로 구조 신호만 담당. 디버깅 / ablation이 깔끔.
- Block B = '재봉합 사건' 인코더(Direction 2) — indel은 SAV와 달리 사슬을 자르고 다시 잇는 사건. residue를 나열(pooling)하지 않고, 그 사건의 구조적 대가(끊긴 두 끝의 거리, 잘려나간 조각의 박힘 정도 등)를 인코딩. 가장 indel다운 정보를 컴팩트하게 담아 SAV=0 스킴과도 궁합이 좋음.
- SAV는 Block B를 0으로 — 치환은 점 하나(Block A)로 변이 전체가 설명되므로 추가 구조 정보가 없음. SAV/indel 구분은 바깥 one-hot이 담당.
- 삽입 feature 유지 — 이 데이터엔 삽입이 2개뿐이라 거의 0이지만, 향후 다른 유전자(삽입 많은 경우)로 확장할 때를 위해 일반 indel 인코더로 남겨둠.
- 정직한 한계 — junction\_strain / junction\_orient\_cos는 이 데이터에서 무신호 (orient\_cos 결실  $\rho = -0.045$ ). 결실이 거의 다 1-residue라 '재봉합 gap'이 변이마다 거의 안 변하기 때문. multi-residue 결실이 많은 유전자에선 살아날 feature라 유지.

### 5. 앞으로 하면 좋을 것 (우선순위 순)

| 할 일                       | 설명                                                                                        |
|---------------------------|-------------------------------------------------------------------------------------------|
| 1. 다운스트림 MLP 연결           | 이 [N,25]을 문서 아키텍처의 구조 MLP 블록에 넣어 실제 예측까지. torch 필요(무거워짐, GPU 서버 권장).                      |
| 2. 다른 feature 블록과 통합      | ESM WT-difference 임베딩 등 다른 입력 블록과 concat하는 전체 파이프라인 조립.                                   |
| 3. junction_orient_cos 정리 | 이 데이터에서 무신호 — 유지하되, 최종 모델에서 ablation으로 기여도 재확인.                                           |
| 4. 외부 검증                  | Hu et al.(2023), Prakash et al.(2024)의 HR proficiency assay로 일반화 확인.                      |
| 5. 다른 유전자 확장              | BRCA-paralog, FANC 등 짧은 유전자로 framework 확장. 삼입 / multi-residue 결실 많은 데이터에서 Block B 진가 재확인. |

## 6. 재현 방법

의존성: numpy, pandas, biotite (구조 인코딩) / reportlab (PDF). torch / scipy 불필요.

inputs/의 파일들을 작업 폴더에 두고 순서대로 실행:

```
python build_dataset.py    # split_manifest.csv → rad51c_X.npy, rad51c_y.npy, features.csv
python analysis.py        # → analysis_results.json (상관 / baseline / AUC)
python generate_report.py  # → 이 PDF
```

## 부록. 25개 feature 전체 — z\_score Spearman 상관

전체 / SAV / 결실 각각에서의 상관. (SAV는 Block B가 0이라 B\_\* 상관은 정의되지 않음/0)

| feature                  | 전체 $\rho$ | SAV $\rho$ | 결실 $\rho$ |
|--------------------------|-----------|------------|-----------|
| A_plddt                  | -0.334    | -0.319     | -0.599    |
| A_ss_helix               | -0.003    | +0.004     | -0.110    |
| A_ss_sheet               | -0.121    | -0.118     | -0.230    |
| A_ss_loop                | +0.096    | +0.086     | +0.281    |
| A_rsasa                  | +0.327    | +0.320     | +0.441    |
| A_dist_walker_a          | +0.317    | +0.316     | +0.392    |
| A_dist_walker_b          | +0.318    | +0.311     | +0.497    |
| A_dist_atp_contact       | +0.297    | +0.297     | +0.379    |
| A_dist_ssDNA_binding     | +0.149    | +0.145     | +0.205    |
| A_dist_bcdx2_interface   | +0.218    | +0.207     | +0.406    |
| A_dist_cx3_interface     | +0.213    | +0.200     | +0.396    |
| B_junction_strain        | -0.226    | +0.000     | +0.002    |
| B_junction_orient_cos    | -0.114    | +0.000     | -0.045    |
| B_seam_both_loop         | -0.073    | +0.000     | +0.291    |
| B_span_min2_rsasa        | -0.202    | +0.000     | +0.442    |
| B_span_max2_plddt        | -0.233    | +0.000     | -0.599    |
| B_span_frac_ss           | -0.210    | +0.000     | -0.281    |
| B_span_min_site_dist     | -0.177    | +0.000     | +0.421    |
| B_seam_mean_rsasa        | -0.215    | +0.000     | +0.501    |
| B_span_external_contacts | -0.234    | +0.000     | -0.443    |
| B_del_len_norm           | -0.229    | +0.000     | -0.044    |
| B_ins_len_norm           | +0.024    | +0.000     | +0.000    |
| oh_sav                   | +0.226    | +0.000     | +0.000    |
| oh_del                   | -0.229    | +0.000     | +0.000    |
| oh_ins                   | +0.024    | +0.000     | +0.000    |